Estimación en R-Stan

Dr. Héctor Nájera
Dr. Curtis Huffman

Pasos en inferencia bayesiana

Pregunta de investigación (Teoría)

Hipótesis
β

Verosimilitud
Datos + Modelo que los explica
P(D\|B)
$Y = a + \hat{\beta}X$

Espacio típico (Donde se muestrea la posterior)

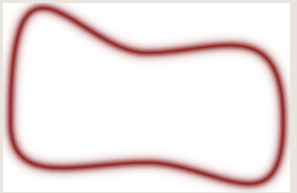

Priors sobre H
$\beta \sim N(0,10)$

Exploración con MCMC

Evaluación de las cadenas: Rhat y ESS

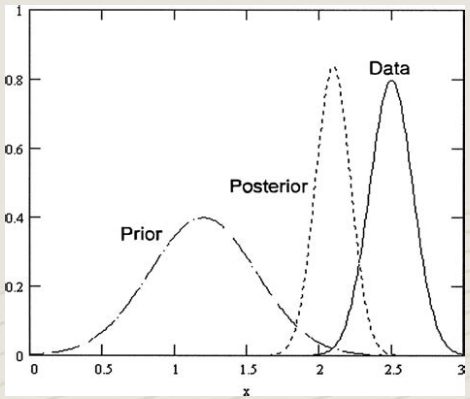

Distribución posterior de β^*

Evaluación de H

Stan: Diferentes plataformas

RStan

The R interface to Stan

Stan está escrito en C++

Programas

- rstan
  - Rstan (crudo)
  - rstan (interfaces para rstan)
    - rstanarm
    - rethinking
    - brms
    - cmdstanr
- PyStan
- Stan.jl
- CmdStan

Tidybayes

bayesplot

Avanzado: mayor potencia y flexibilidad

Intermedio: menor flexibilidad

Intermediarios: brms y rstanarm

Además brms conecta con cmdstanr y puede ser multicore y multithread –y ahora se puede usar con las tarjetas gráficas- dentro de cada cadena!

Noten las combinaciones posibles:
- Modelo espacio/temporal (AR y CAR) inflado de ceros!!!!

brms offers more modeling capabilities, flexibility with priors, and more[3]

	brms	rstanarm
Supported model types:		
Linear models	yes	yes
Robust linear models	yes	yes[1]
Binomial models	yes	yes
Categorical models	yes	no
Multinomial models	no	no
Count data models	yes	yes
Survival models	yes[2]	yes
Ordinal models	various	cumulative[3]
Zero-inflated and hurdle models	yes	no
Generalized additive models	yes	yes
Non-linear models	yes	no
Additional modeling options:		
Variable link functions	various	various
Weights	yes	yes
Offset	yes	yes
Multivariate responses	limited	no
Autocorrelation effects	yes	no
Category specific effects	yes	no
Standard errors for meta-analysis	yes	no
Censored data	yes	no
Truncated data	yes	no
Customized covariances	yes	no
Missing value imputation	no	no
Bayesian specifics:		
parallelization	yes	yes
population-level priors	flexible	normal, Student-t
group-level priors	normal	normal
covariance priors	flexible	restricted[5]
Other:		
Estimator	HMC, NUTS	HMC, NUTS
Information criterion	WAIC, LOO	AIC, LOO
C++ compiler required	yes	no
Modularized	no	no

Spatial models

Si no se puede hay que usar rstan

¿Intermediario?

- Brms:

```
M1.I<-brm(ins_ali_mo_3 ~ ed_jefe_2 + ed_jefe_3 +   ed_jefe_4 + ed_jefe_5
+ sexo_jefe_1 + edad_jefe + niv_ed_prom + tv + compu +
refri  +   lavad  +   tvpaga   + hablaind  +  tinaco  + internet + tot_integ +
salario_mun +
i_nolav +    i_nostvp + i_noref + salario_ent + rural + (1|id_mun) +
(1|clave_ent),
data=DI, family = bernoulli(),
prior = c(set_prior("normal(0,1)", class = "b"),
set_prior("normal(0,5)", class= "sd")),
warmup = 400, iter = 1800, control = list(adapt_delta = .96),
chains = 2, cores=14, threads = threading(14, grainsize = 100),backend =
"cmdstanr")
```

STAN:

```
functions {
  /* integer sequence of values
   * Args:
   *   start: starting integer
   *   end: ending integer
   * Returns:
   *   an integer sequence from start to end
   */
  int[] sequence(int start, int end) {
    int seq[end - start + 1];
    for (n in 1:num_elements(seq)) {
      seq[n] = n + start - 1;
    }
    return seq;
  }
  // compute partial sums of the log-likelihood
  real partial_log_lik_lpmf(int[] seq, int start, int end, data int[] Y, data matrix Xc, vector b, real Intercept, data int[] J_1, data vector
Z_1_1, vector r_1_1, data int[] J_2, data vector Z_2_1, vector r_2_1) {
    real ptarget = 0;
    int N = end - start + 1;
    // initialize linear predictor term
    vector[N] mu = Intercept + rep_vector(0.0, N);
    for (n in 1:N) {
      // add more terms to the linear predictor
      int nn = n + start - 1;
      mu[n] += r_1_1[J_1[nn]] * Z_1_1[nn] + r_2_1[J_2[nn]] * Z_2_1[nn];
    }
    ptarget += bernoulli_logit_glm_lpmf(Y[start:end] | Xc[start:end], mu, b);
    return ptarget;
  }
}
data {
  int<lower=1> N;  // total number of observations
  int Y[N];  // response variable
  int<lower=1> K;  // number of population-level effects
  matrix[N, K] X;  // population-level design matrix
  int grainsize;  // grainsize for threading
  // data for group-level effects of ID 1
  int<lower=1> N_1;  // number of grouping levels
  int<lower=1> M_1;  // number of coefficients per level
  int<lower=1> J_1[N];  // grouping indicator per observation
```

STAN Cont.

```
STAN
 // group-level predictor values
  vector[N] Z_1_1;
  // data for group-level effects of ID 2
  int<lower=1> N_2;  // number of grouping levels
  int<lower=1> M_2;  // number of coefficients per level
  int<lower=1> J_2[N];  // grouping indicator per observation
  // group-level predictor values
  vector[N] Z_2_1;
  int prior_only;  // should the likelihood be ignored?
}
transformed data {
  int Kc = K - 1;
  matrix[N, Kc] Xc;  // centered version of X without an intercept
  vector[Kc] means_X;  // column means of X before centering
  int seq[N] = sequence(1, N);
  for (i in 2:K) {
    means_X[i - 1] = mean(X[, i]);
    Xc[, i - 1] = X[, i] - means_X[i - 1];
  }
}
parameters {
  vector[Kc] b;  // population-level effects
  real Intercept;  // temporary intercept for centered predictors
  vector<lower=0>[M_1] sd_1;  // group-level standard deviations
  vector[N_1] z_1[M_1];  // standardized group-level effects
  vector<lower=0>[M_2] sd_2;  // group-level standard deviations
  vector[N_2] z_2[M_2];  // standardized group-level effects
}
transformed parameters {
  vector[N_1] r_1_1;  // actual group-level effects
  vector[N_2] r_2_1;  // actual group-level effects
  r_1_1 = (sd_1[1] * (z_1[1]));
  r_2_1 = (sd_2[1] * (z_2[1]));
}
model {
  // likelihood including constants
  if (!prior_only) {
    target += reduce_sum(partial_log_lik_lpmf, seq, grainsize, Y, Xc, b, Intercept, J_1, Z_1_1, r_1_1, J_2, Z_2_1, r_2_1);
  }
  // priors including constants
  target += normal_lpdf(b | 0,1);
  target += student_t_lpdf(Intercept | 3, 0, 2.5);
  target += normal_lpdf(sd_1 | 0,5)
```

LLM e inferencia

¿Por dónde empezar brms o stan?

La escritura de los modelos bayesianos tiene la ventaja de que es necesario saber lo que uno está haciendo

Escribir el modelo estadístico no es necesariamente saber el modelo estadístico

Los LLM (DeepSeek, ChatGpt, …) facilitan la escritura/traducción del código pero eso es insuficiente para hacer inferencias válidas

El paquete brms es genial porque es una interface muy amigable para estimar modelos bayesianos en stan pero debe enseñarse después y no antes de la escritura en stan

En el mercado de trabajo va a importar menos que puedan usar brms y más que sepan stan.

La gente más buscada para estimar modelos es la que tenga acceso al mayor poder en LLMs y el conocimiento más sólido de stan

Estructura de modelo bayesiano

Estructura de un modelo Bayesiano:

$$
\begin{aligned}
\text{outcome}_i &\sim \text{Normal}(\mu_i, \sigma) \\
\mu_i &= \beta \times \text{predictor}_i \\
\beta &\sim \text{Normal}(0, 10) \\
\sigma &\sim \text{HalfCauchy}(0, 1)
\end{aligned}
$$

$$
\begin{aligned}
D_i &\sim \text{Normal}(\mu_i, \sigma) \\
\mu_i &= \alpha + \beta_A A_i \\
\alpha &\sim \text{Normal}(10, 10) \\
\beta_A &\sim \text{Normal}(0, 1) \\
\sigma &\sim \text{Uniform}(0, 10)
\end{aligned}
$$

$$
\begin{aligned}
D_i &\sim \text{Normal}(\mu_i, \sigma) && \text{[likelihood]} \\
\mu_i &= \alpha + \beta_R R_i + \beta_A A_i && \text{[linear model]} \\
\alpha &\sim \text{Normal}(10, 10) && \text{[prior for } \alpha\text{]} \\
\beta_R &\sim \text{Normal}(0, 1) && \text{[prior for } \beta_R\text{]} \\
\beta_A &\sim \text{Normal}(0, 1) && \text{[prior for } \beta_A\text{]} \\
\sigma &\sim \text{Uniform}(0, 10) && \text{[prior for } \sigma\text{]}
\end{aligned}
$$

https://mc-stan.org/docs/stan-users-guide/linear-regression.html

Pasos para la modelación

Especificación del modelo (likelihood y priors)

Gibbs:
- Rjags + Jags(windows)

Hamiltonian:
Rstan + Interface de su preferencia

1. Preparación de datos
2. Escritura del modelo (verosimilitud y prior)
3. Compilación
4. Estimación de MCMC
5. Inspección de resultados
6. Diagnósticos

Software

- Programa: R + Rstudio
- Algoritmo HMC: Rstan
- Interface: brms + cmdstan

CmdStanR

Paso 1

- Instalar (asegurarse) R version 4 o superior:

https://cran.r-project.org/bin/windows/base/

Paso 2

- Instalar Rstudio

https://www.rstudio.com/products/rstudio/download/#download

Paso 3

- Instalar Rtools 4.0 o superior

https://cran.r-project.org/bin/windows/Rtools/

Paso 4

- Instalar Rstan

Seguir estos pasos

https://github.com/stan-dev/rstan/wiki/RStan-Getting-Started

Asegurarse que el ejemplo “corre”

Paso 5

- Instalar en Rstudio

Brms, tidybayes, bayesplot, posterior, tidyverse

Paso 6

- Instalar cmdstanr –mayor rapidez-

https://mc-stan.org/cmdstanr/

Introducción –refrescando- R Software

- Algunas guías
  - https://www.youtube.com/watch?v=_V8eKsto3Ug

GitHub

- https://github.com/hectornajera83/ClaseBayes2025